Rapport de stage

Développement de modèles probabilistes multi-horizons pour la prévision de la vapeur d'eau précipitable à l'Instituto de Astrofísica de Canarias

Felix Vernin
Élève ingénieur à l'ESIEE Paris
Stage réalisé à l'Instituto de Astrofísica de Canarias — IAC

Durée : six mois
Période : Avril-Septembre
Tuteur IAC : Andrés Asensio Ramos
Tuteur ESIEE : Valentin Belin

Remerciements

Je tiens tout d'abord à remercier **Andrés Asensio Ramos** pour son encadrement, ses conseils scientifiques et la confiance qu'il m'a accordée pendant toute la durée de mon stage à l'Instituto de Astrofísica de Canarias.

Je remercie également **Casiana Muñoz-Tuñón** pour son expertise sur les conditions d'observation astronomique aux Canaries et pour sa contribution à la réflexion scientifique menée autour de la vapeur d'eau précipitable.

Je remercie l'ensemble des membres de l'équipe pour leur accueil, leur disponibilité et les échanges qui m'ont permis de mieux comprendre les contraintes opérationnelles et scientifiques propres aux observatoires astronomiques.

Enfin, je remercie l'ESIEE Paris ainsi que **Valentin Belin** pour le suivi de ce stage et pour les enseignements qui m'ont permis de mener ce projet à bien.

Résumé

Les observations astronomiques réalisées depuis le sol sont fortement dépendantes des conditions atmosphériques. Dans le domaine infrarouge, la vapeur d'eau présente dans l'atmosphère absorbe une partie importante du rayonnement reçu. La quantité totale de vapeur d'eau dans une colonne atmosphérique est mesurée par la vapeur d'eau précipitable, ou Precipitable water vapor (PWV). Une anticipation fiable de son évolution constitue donc un enjeu important pour la planification des observations astronomiques.

Mon stage de six mois à l'Instituto de Astrofísica de Canarias avait pour objectif d'étudier la faisabilité d'un système de prévision probabiliste du PWV à plusieurs horizons, allant de 30 minutes à 32 heures. Contrairement à une prévision ponctuelle classique, l'approche probabiliste vise à produire une distribution prédictive permettant d'estimer à la fois une valeur probable du PWV, son incertitude et la probabilité de dépasser un seuil opérationnel.

J'ai construit un pipeline complet de traitement et de modélisation à partir de mesures effectuées toutes les 30 minutes entre le 1er janvier 2012 et le 31 décembre 2013. J'ai réalisé le nettoyage et la synchronisation des données, conçu des variables temporelles et météorologiques, puis comparé plusieurs familles de modèles, notamment XGBoost, LSTM, BiLSTM et NGBoost. J'ai ensuite approfondi l'approche NGBoost, qui permet de prédire les paramètres d'une distribution de probabilité, et développé une procédure de calibration des intervalles prédictifs.

Les résultats confirment la faisabilité de la prévision du PWV par apprentissage automatique. Les performances se dégradent néanmoins avec l'horizon temporel, tandis que les variations rares et brutales du PWV restent difficiles à anticiper en raison de leur faible représentation dans les données. J'ai enfin développé un tableau de bord interactif permettant d'examiner les prévisions, leurs intervalles d'incertitude et les situations dans lesquelles le modèle échoue.

Ce travail a également servi de base à la préparation d'une publication scientifique en anglais, envisagée avec Andrés Asensio Ramos et Casiana Muñoz-Tuñón.

Mots-clés **:** astronomie, vapeur d'eau précipitable, séries temporelles, prévision probabiliste, NGBoost, calibration, incertitude, machine learning.

1. Introduction

1.1. Les contraintes de l'observation astronomique

La qualité des observations astronomiques réalisées depuis le sol dépend directement de l'état de l'atmosphère. La couverture nuageuse, la turbulence, les aérosols, le vent et la vapeur d'eau modifient la propagation du rayonnement électromagnétique avant son arrivée sur les instruments.

Ces perturbations sont particulièrement importantes pour les observations infrarouge, visible par la forte absorption sur les bandes infrarouges fig.1. La vapeur d'eau atmosphérique possède de nombreuses bandes d'absorption dans ce domaine spectral. Une augmentation du PWV peut donc réduire la transmission atmosphérique, augmenter le bruit de fond et rendre certaines observations difficiles, voire impossibles.

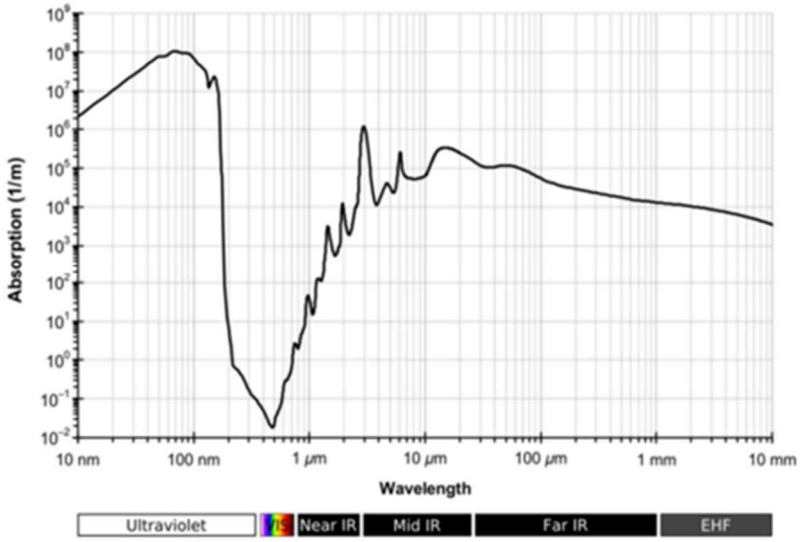


Fig.1 Absorption de la vapeur d'eau sur un spectre étendu (src : Wikipedia.org)

Le temps d'utilisation d'un télescope représente une ressource scientifique et financière précieuse. Une mauvaise anticipation des conditions atmosphériques peut conduire à programmer un instrument infrarouge pendant une période défavorable. Inversement, une prévision fiable peut faciliter l'allocation dynamique du temps d'observation et contribuer à sélectionner les programmes scientifiques les mieux adaptés aux conditions attendues.

1.2. Présentation de l'Instituto de Astrofísica de Canarias

J'ai réalisé mon stage à l'**Instituto de Astrofísica de Canarias (IAC)**, organisme espagnol consacré à la recherche, au développement technologique et à l'exploitation d'infrastructures astronomiques. Fondé en 1975, l'IAC est aujourd'hui un centre de référence international dans le domaine de l'astrophysique. Il figure parmi les institutions scientifiques les plus reconnues dans le domaine de l'observation astronomique, notamment grâce à la qualité des infrastructures installées aux Canaries et aux nombreux projets de recherche auxquels il participe.

L'IAC joue notamment un rôle majeur dans les activités scientifiques et techniques associées aux **Observatoires des Canaries**, qui comptent parmi les sites astronomiques les plus importants au monde. Leur situation géographique, leur altitude et leurs conditions atmosphériques offrent une qualité de ciel particulièrement favorable à l'observation astronomique. La qualité astronomique du ciel y est également protégée par la loi espagnole n° 31/1988 du 31 octobre 1988, qui encadre notamment l'éclairage extérieur, les perturbations radioélectriques et certaines sources de pollution atmosphérique.

Le rayonnement international de l'IAC repose ainsi à la fois sur ses activités de recherche et sur sa participation à l'exploitation d'infrastructures astronomiques de premier plan. Les observatoires des Canaries accueillent notamment des instruments et des télescopes utilisés par des équipes scientifiques provenant de nombreux pays, faisant de l'archipel un lieu majeur de la recherche astronomique mondiale.

Mon travail portait sur des données associées au site d'**Izaña, à Tenerife,** voir fig.2. Le projet s'inscrivait dans cette démarche de recherche et d'amélioration des performances des observations astronomiques, avec pour objectif de contribuer à une meilleure caractérisation et à une meilleure anticipation des conditions atmosphériques utiles à l'observation.



Fig.2 Observatoire d'Izaña (*src : Diario de Avisos)*

1.3. Présentation de l'équipe et encadrement

J'ai été encadré par **Andrés Asensio Ramos**, chercheur à l'IAC, avec la participation scientifique de **Casiana Muñoz-Tuñón,** elle aussi chercheur a l'IAC.

Mon stage se situait à l'interface entre plusieurs domaines :

- L'astronomie observationnelle,
- Les sciences atmosphériques,
- La science des données,
- L'apprentissage automatique,
- La modélisation probabiliste,
- Le développement logiciel.

Cette interdisciplinarité m'a conduit à traduire une problématique astronomique en un protocole de prévision de séries temporelles, puis à concevoir les outils nécessaires pour évaluer la pertinence opérationnelle des résultats.

1.4. Définition du PWV

Le Precipitable Water Vapor correspond à la hauteur d'eau liquide qui serait obtenue si toute la vapeur d'eau contenue dans une colonne atmosphérique était condensée. Il est généralement exprimé en millimètres.

Le PWV ne correspond donc pas à une quantité de pluie mesurée au sol. Il représente le contenu intégré en vapeur d'eau de l'atmosphère au-dessus du site considéré.

1.5. Problématique

La question centrale du stage peut être formulée ainsi :

Est-il possible de prévoir de manière fiable et probabiliste l'évolution du PWV à Izaña, de 30 minutes à plus de 24 heures, à partir des mesures locales disponibles ?

Cette question contient deux enjeux complémentaires :

1. Prévoir la valeur future du PWV,
2. Quantifier l'incertitude associée à chaque prévision,

1.6. Objectifs du stage

Pour répondre à cette problématique, j'ai défini les objectifs suivants :

- Construire un pipeline reproductible de préparation des données,
- Créer des variables permettant de représenter les tendances atmosphériques,
- Comparer plusieurs architectures de machine learning,
- Produire une prévision distincte pour chaque horizon,
- Modéliser explicitement l'incertitude prédictive,
- Evaluer et calibrer les probabilités produites,
- Analyser les situations d'échec, notamment les pics soudains,
- Concevoir un tableau de bord interactif,
- Préparer la valorisation scientifique du travail sous la forme d'une publication.

2. Données et préparation du jeu d'étude

2.1. Origine et période des données

L'étude repose sur un historique couvrant la période du 1er janvier 2012 au 31 décembre 2013. Les observations sont disponibles avec une fréquence native de 30 minutes.

La source principale de mesure du PWV est la **station GNSS** située à Izaña, qui dérive la vapeur d'eau précipitable à partir du retard troposphérique au zénith (ZTD) des signaux GPS. Le ZTD est d'abord séparé en une composante hydrostatique (ZHD), calculée à partir de la pression atmosphérique mesurée au sol via le modèle de Saastamoinen, et une composante humide (ZWD). Le PWV est ensuite obtenu par conversion du ZWD à l'aide de la température moyenne pondérée de la colonne atmosphérique.

Le jeu de données contient environ **35 088 observations temporelles** et **huit colonnes principales** dans sa version initialement analysée.

Les données comprennent notamment :

- le timestamp,
- le délai troposphérique zénithal tzd_mm,
- la pression atmosphérique press_hpa,
- la température temp_k,
- la mesure de PWV utilisée comme cible pwv_mm,
- la mesure de pwv brute raw_pwv
- l'incertitude instrumentale error_mm,
- plusieurs variables météorologiques complémentaires.

2.2. Première stratégie et abandon des données satellitaires

Le projet devait initialement combiner les mesures locales avec des données satellitaires issues d'EUMETSAT, accessibles par l'intermédiaire de l'outil NATEX.

J'ai réalisé plusieurs essais d'extraction et apporté différentes modifications au pipeline. Toutefois, les temps de récupération, l'instabilité des flux et les difficultés d'automatisation compromettaient la fiabilité d'un futur fonctionnement en temps réel.

J'ai donc recentré l'étude sur les mesures locales. Cette décision a permis de construire un pipeline plus stable et de concentrer le travail sur la modélisation probabiliste. Elle limite néanmoins la capacité du modèle à anticiper certains changements atmosphériques qui ne sont pas encore visibles dans les capteurs du site.

2.3. Analyse des données manquantes

Le jeu analysé comprend 35 088 lignes et huit colonnes, soit 280 704 cellules. J'ai identifié **11 769 cellules manquantes**, représentant environ **4,19 %** de l'ensemble.

Au total, **2 610 lignes**, soit **7,44 %**, comportent au moins une valeur manquante.

Variable	Valeurs manquantes	Proportion
raw_pwv_mm	2 610	7,44 %
pwv_mm	2 610	7,44 %
error_mm	2 610	7,44 %
press_hpa	1 987	5,66 %
temp_k	1 321	3,77 %
tzd_mm	631	1,80 %
Timestamp	0	0 %

Pour les variables explicatives, j'ai intégré dans le pipeline une imputation par la médiane. L'imputeur est ajusté exclusivement sur les données d'entraînement, puis appliqué aux ensembles de validation et de test.

2.4. Statistiques descriptives du PWV

La distribution du PWV présente les caractéristiques suivantes :

Statistique	Valeur
Moyenne	4,51 mm
Médiane	3,60 mm
Écart-type	3,80 mm
Maximum	22,57 mm
Asymétrie	1,2828
Kurtosis	1,8

La moyenne supérieure à la médiane et l'asymétrie positive indiquent une distribution étirée vers les valeurs élevées, voir fig.3. Les épisodes de PWV très élevé sont rares, mais ils ont une importance opérationnelle majeure.

Cette distribution déséquilibrée représente une difficulté pour l'apprentissage. Un modèle minimisant une erreur moyenne peut obtenir de bonnes performances globales tout en reproduisant imparfaitement les événements extrêmes.

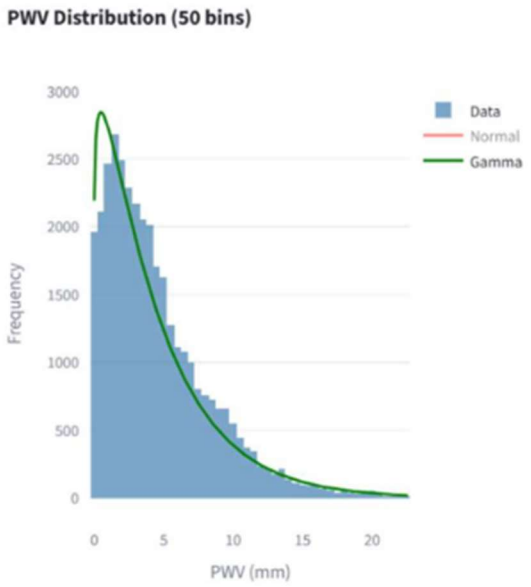


Fig.3 Distribution du pwv dans le dataset

Source : calculs de l'auteur à partir des données de l'IAC

3. Ingénierie des variables

3.1. Objectif

L'absence de prévisions météorologiques externes rend l'exploitation de l'historique local particulièrement importante. J'ai créé des variables destinées à représenter :

- le niveau récent du PWV,
- sa tendance,
- son accélération,
- sa variabilité locale,
- les cycles journaliers et saisonniers,
- l'état météorologique mesuré au même instant.

Toutes les variables sont construites uniquement à partir des informations disponibles au moment de la prévision.

3.2. Retards temporels

J'ai utilisé les retards suivants :

lags = [1, 2, 3, 4, 6, 8, 12, 24]

Avec une fréquence de 30 minutes, ils représentent respectivement :

Retard	Durée
1	30 minutes
2	1 heure
3	1 h 30
4	2 heures
6	3 heures
8	4 heures
12	6 heures
24	12 heures

3.3. Différences et accélérations

Pour aider le modèle à reconnaître les changements de tendance, j'ai calculé plusieurs différences :

- pwv_diff_1 = pwv_mm.diff(1)
- pwv_diff_2 = pwv_mm.diff(2)
- pwv_diff_4 = pwv_mm.diff(4)

J'ai également calculé des approximations de dérivée seconde :

- pwv_accel_1 = pwv_diff_1.diff(1)
- pwv_accel_2 = pwv_diff_2.diff(1)

Ces variables ont pour objectif de distinguer un niveau stable de PWV d'une phase de hausse ou de baisse rapide.

3.4. Statistiques glissantes

J'ai ajouté des moyennes et écarts-types glissants sur le PWV et son accélération :

```
roll_acc = out["pwv_accel_1"].rolling(window=6)
out["pwv_accel_roll_mean_6"] = roll_acc.mean()
out["pwv_accel_roll_std_6"] = roll_acc.std()

roll = out["pwv_mm"].rolling(window=6)
out["pwv_roll_mean_6"] = roll.mean()
out["pwv_roll_std_6"] = roll.std()
```

Une fenêtre de six observations représente trois heures. Elle permet de réduire l'effet du bruit ponctuel tout en conservant une information sur la dynamique récente.

J'ai testé des longueurs de contexte comprises entre 8 et 128 observations.
L'optimisation par Optuna a sélectionné une fenêtre de 48 observations, soit 24 heures.

3.5. Encodage cyclique

Les heures et les jours de l'année sont cycliques. Une représentation numérique directe introduirait une discontinuité artificielle entre 23 h et 0 h, ou entre le 31 décembre et le 1er janvier.

J'ai donc utilisé un encodage sinusoïdal :

$$hour_sin = \sin(2\pi \frac{hour}{24})$$

$$hour_cos = cos(2\pi \frac{hour}{24})$$

$$day_sin = sin(2\pi \frac{day}{365})$$

$$day_cos = cos(2\pi \frac{day}{365})$$

L'emploi simultané du sinus et du cosinus permet de représenter sans ambiguïté chaque position dans le cycle.

3.6. Sélection des variables

J'ai étudié l'importance des variables fournie par NGBoost. J'ai également réalisé des essais de sélection. Les meilleures performances ont finalement été obtenues en conservant l'ensemble des variables disponibles.

4. Protocole expérimental

4.1. Prévisions directes et multi-horizons

J'ai retenu une stratégie de prévision directe : un modèle indépendant est entraîné pour chaque horizon.

Le modèle apprend directement la relation entre les informations disponibles à l'instant et le PWV observé à l'instant.

Cette stratégie évite l'accumulation des erreurs propre aux prévisions récursives. Elle nécessite en revanche l'entraînement et la maintenance d'un modèle distinct pour chaque horizon.

4.2. Découpage chronologique

Pour respecter la structure temporelle des données, je n'ai pas utilisé de découpage aléatoire.

Le découpage final suit l'ordre chronologique :

- 80 % pour la phase d'apprentissage et d'optimisation,
- 10 % pour la validation,
- 10 % pour le test final.

L'ensemble de test correspond donc à la période la plus récente du jeu de données et n'est pas utilisé pendant la sélection des hyperparamètres.

À l'intérieur des données d'apprentissage, j'ai utilisé TimeSeriesSplit. Chaque fold contient une fenêtre d'entraînement croissante ainsi qu'une fenêtre de validation située chronologiquement après cette dernière.

Il ne s'agit pas d'une fenêtre glissante de largeur constante, mais d'une validation à origine croissante.

4.3. Prévention des fuites de données

J'ai pris plusieurs précautions pour empêcher le modèle d'utiliser directement ou indirectement une information future :

- Conservation de l'ordre chronologique,
- Création des retards uniquement à partir de valeurs passées,
- Calcul des statistiques glissantes sans inclure la cible future,
- Ajustement de l'imputation exclusivement sur l'entraînement,
- Ajustement de la normalisation exclusivement sur l'entraînement,
- Réajustement du prétraitement à l'intérieur de chaque fold,
- Séparation du test avant l'optimisation des hyperparamètres.

Pour les variables explicatives, le pipeline applique :

1. Un SimpleImputer(strategy="median"),
2. Un StandardScaler.

Pour la cible, j'ai utilisé un RobustScaler, également ajusté uniquement sur les valeurs d'apprentissage.

Cette procédure constitue un point essentiel du protocole : ajuster le prétraitement sur tout le dataset aurait transmis au modèle des informations statistiques sur la période de test.

4.4. Baseline de persistance

La baseline principale est le modèle de persistance, surnommé « modèle perroquet ». Il suppose que le PWV futur sera égal à la dernière valeur connue :

$$\widehat{PWV_{t+h}} = PWV_t$$

Cette baseline n'est pas triviale à battre aux horizons courts, car les séries atmosphériques présentent une forte autocorrélation.

Un modèle complexe n'est réellement utile que s'il apporte une amélioration par rapport à cette règle simple, notamment pendant les changements de tendance.

4.5. Métriques déterministes

J'ai utilisé la MAE, la RMSE et le coefficient de détermination.

Erreur absolue moyenne

$$\boldsymbol{MAE} = \frac{\mathbf{1}}{\boldsymbol{n}}\sum|\boldsymbol{y_i} - \boldsymbol{\hat{y}_i}|$$

La MAE est exprimée en millimètres de PWV et fournit une mesure facilement interprétable de l'erreur moyenne.

Racine de l'erreur quadratique moyenne

$$\boldsymbol{RMSE} = \sqrt{\frac{\mathbf{1}}{\boldsymbol{n}}\sum(\boldsymbol{y_i} - \boldsymbol{\hat{y}_i})^2}$$

La RMSE pénalise davantage les erreurs importantes. Elle est utile pour mesurer l'impact des pics mal anticipés.

Coefficient de détermination

$$\boldsymbol{R^2} = \mathbf{1} - \frac{\sum(\boldsymbol{y_i} - \boldsymbol{\hat{y}_i})^2}{\sum(\boldsymbol{y_i} - \boldsymbol{\bar{y}_i})^2}$$

Un coefficient proche de 1 indique que le modèle explique une part importante de la variabilité observée.

4.6. Métriques probabilistes

Pour évaluer NGBoost, j'ai utilisé le **Continuous Ranked Probability Score**, ou CRPS. Cette métrique compare l'ensemble de la distribution prédictive à la valeur observée :

$$CRPS(F, y) = \int_{-\infty}^{\infty} \left(F(x) - \mathbb{1}_{\{x \geq y\}}\right)^2 dx$$

Une valeur faible est préférable. Le CRPS récompense à la fois :

- Une prévision centrée près de la valeur réelle,
- Une distribution suffisamment étroite,
- Une représentation réaliste de l'incertitude.

J'ai également contrôlé la couverture empirique des intervalles à 68%, 95%, 99%.

Pour un intervalle nominal à 95 %, environ 95 % des observations doivent se situer à l'intérieur de l'intervalle si le modèle est correctement calibré.

5. Modèles étudiés

5.1. Modèles déterministes

J'ai comparé plusieurs modèles : XGBoost, Random Forest, LSTM, BiLSTM, Transformer, modèles de classification ainsi que NGBoost.

Les modèles reçoivent les mêmes périodes d'apprentissage et de test. Lorsque leur architecture le permet, ils utilisent les mêmes familles de variables.

Les modèles XGBoost et les réseaux récurrents offrent de bonnes performances ponctuelles, surtout aux horizons courts. Ils ne produisent cependant pas directement une distribution probabiliste complète aussi exploitable que celle de NGBoost.

5.2. Limites de la classification

J'ai d'abord formulé le problème sous la forme suivante :

Le PWV dépassera-t-il 5 mm à l'horizon considéré ?

Cette formulation fournit une réponse directement interprétable. Elle perd néanmoins une partie de l'information contenue dans la cible continue.

Une valeur prévue à 5,1 mm et une valeur prévue à 10 mm appartiennent à la même classe alors que leurs implications peuvent être différentes. De plus, la probabilité produite par un classifieur n'est pas nécessairement calibrée.

J'ai donc privilégié la prévision d'une distribution continue, à partir de laquelle il est possible de calculer la probabilité de dépassement de n'importe quel seuil.

5.3. NGBoost

NGBoost est une méthode de boosting probabiliste. Au lieu de prédire uniquement une valeur ponctuelle, le modèle estime les paramètres d'une distribution conditionnelle :

$$Y \mid X = x \sim \mathcal{D}\big(\theta(x)\big)$$

Dans mon implémentation, j'ai utilisé :

- NGBRegressor,
- NGBoost 0.5.10,
- Une distribution normal,
- Un DecisionTreeRegressor comme apprenant élémentaire,
- La fonction de score CRPS,
- Le gradient naturel,
- Optuna pour l'optimisation des hyperparamètres.

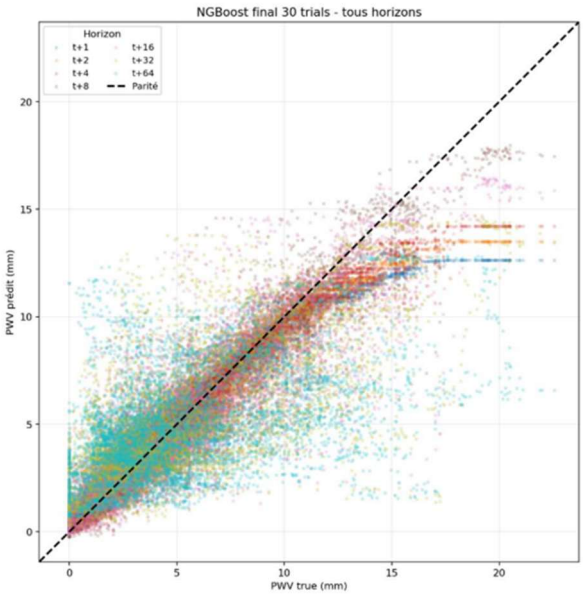


Fig.4 PWV prédit en fonction du PWV réel des modèles de tous les horizons

Source : calculs de l'auteur à partir des données de l'IAC

Pour une distribution normale, le modèle estime une moyenne et un écart-type :

$$PWV \mid X = x \sim N(\mu(x), \sigma(x)^2)$$

La moyenne constitue la prévision centrale (points rouges sur la fig.5). L'écart-type représente l'incertitude estimée (bande orange).

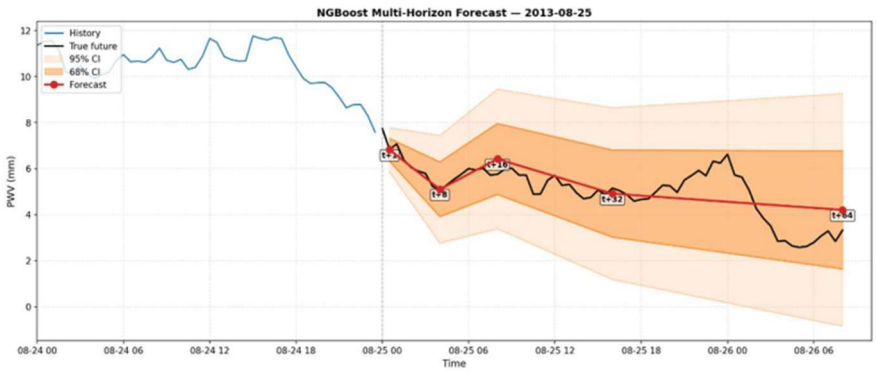


Fig.5 Exemple de prédiction NGBoost *Source : calculs de l'auteur à partir des données de l'IAC*

5.4. Optimisation des hyperparamètres

J'ai utilisé Optuna pour sélectionner les hyperparamètres de chaque horizon. L'objectif d'optimisation est le CRPS moyen calculé par validation chronologique avec TimeSeriesSplit.

Les principaux hyperparamètres optimisés sont :

- le nombre d'estimateurs,
- le taux d'apprentissage,
- la proportion d'observations utilisée par itération,
- la proportion de variables utilisée,
- la profondeur des arbres,

Horizon	Estimateurs	Learning rate	Minibatch	Colonnes	Profondeur
30 min	285	0,0118	1,0	0,5	2
1 h	185	0,0180	1,0	0,5	2
2 h	119	0,0288	1,0	0,5	2
4 h	359	0,0265	0,5	0,5	2
8 h	1 215	0,0108	0,5	0,5	2
16 h	1 399	0,0275	0,5	0,5	2
32 h	4 290	0,0280	0,5	0,5	2

Ces paramètres montrent que les horizons éloignés nécessitent davantage d'itérations. La profondeur reste faible, ce qui réduit le risque de surapprentissage de chaque arbre.

6. Lutte contre la persistance

6.1. Identification du problème

Lors des premiers essais, j'ai observé que certains modèles reproduisaient principalement la dernière valeur connue du PWV. Ce phénomène était particulièrement visible aux horizons courts, notamment de 30 minutes à quatre heures,.

Ce comportement produit de bonnes métriques pendant les périodes stables, mais entraîne un retard systématique lorsque le PWV commence à augmenter ou à diminuer, comme sur l'exemple de la fig.6.

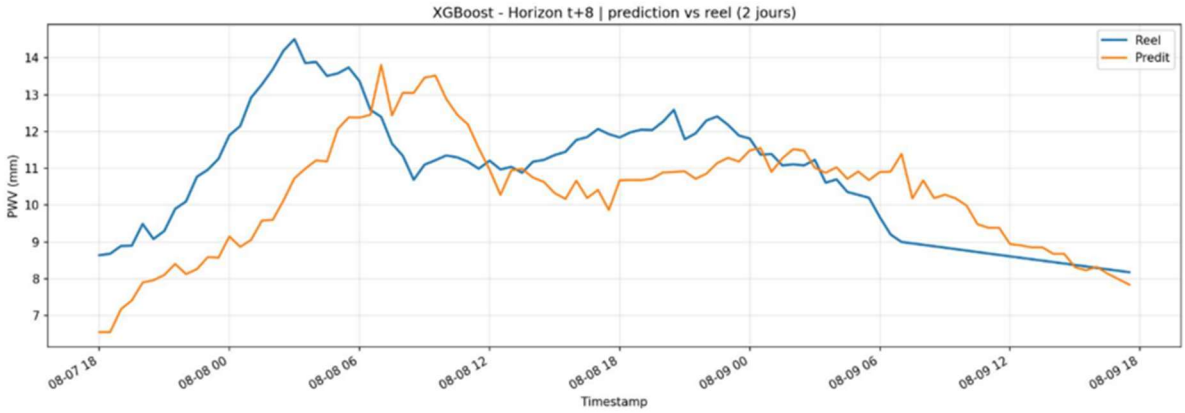


Fig.6. Exemple d'un Modèle persistant (XGBoost)

Source : calculs de l'auteur à partir des données de l'IAC

6.2. Stratégies expérimentées

Pour réduire cette tendance à la persistance, j'ai expérimenté :

- L'ajout de dérivées premières,
- L'ajout de dérivées secondes,
- Différentes longueurs de fenêtre historique,
- Des moyennes glissantes,
- Plusieurs méthodes de normalisation,
- L'optimisation des hyperparamètres,
- Des fonctions de perte accordant plus de poids aux erreurs de tendance,

- Des pénalités lorsque la direction prévue est différente de la direction observée,

J'ai comparé des fonctions faiblement (en bleu sur la fig.7) et fortement (en rouge) punitives. Une pénalisation trop forte peut améliorer la sensibilité aux changements tout en dégradant la MAE ou en produisant des réactions excessives au bruit. J'ai donc cherché un compromis entre précision globale, anticipation des variations et stabilité.

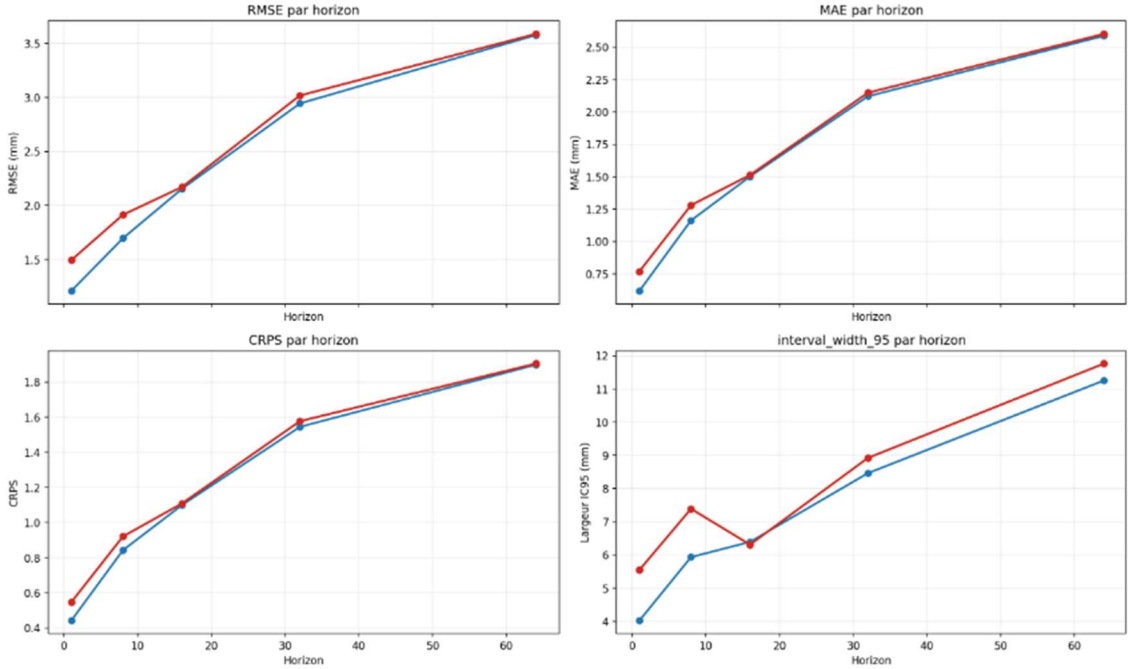


Fig.7 Comparaison des KPI en fonction des fonctions de pertes (Rouge : Très punitive ; Bleu : Peu punitives)

Source : calculs de l'auteur à partir des données de l'IAC

6.3. Limite méthodologique

Même après ces modifications, il n'est pas possible d'éliminer complètement la persistance. Lorsque seules les mesures passées du site sont disponibles, un événement provoqué par une masse d'air encore éloignée peut être impossible à anticiper.

L'ajout futur de prévisions météorologiques externes, de données satellitaires ou d'informations provenant de sites voisins constitue donc une piste importante.

7. Calibration de l'incertitude

7.1. Pourquoi calibrer les probabilités ?

Une distribution probabiliste n'est utile que si l'incertitude qu'elle représente est cohérente avec les erreurs réellement observées.

Un intervalle trop étroit traduit un excès de confiance. Un intervalle trop large produit une prévision prudente mais peu informative.

7.2. Évaluation et calibration de la couverture

Pour chaque niveau nominal q, j'ai calculé la couverture empirique :

$$Coverage(q) = \frac{1}{n}\sum_{i=1}^{n} 1\{y_i \in I_i(q)\}$$

J'ai comparé les couvertures théoriques de 68 %, 95 % et 99 % aux couvertures observées (voir premier graphique de la fig.8). J'ai calibré séparément chaque modèle, car l'erreur et l'incertitude augmententent avec l'horizon. Une correction unique appliquée à tous les horizons n'aurait pas tenu compte de cette dégradation progressive.

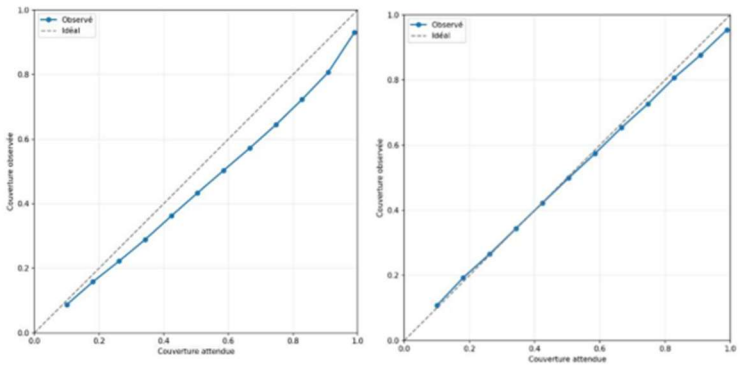


Fig.8 Couverture empirique en fonction de la couverture nominale, avant et après calibration. *Source : calculs de l'auteur à partir des données de l'IAC*

8. Résultats

8.1. Synthèse des performances de NGBoost

Les principaux résultats du modèle NGBoost optimisé sont les suivants :

Horizon	MAE	RMSE	R^2	Temps d'entraînement
30 min	0,57 mm	1,13 mm	0,92	19,03 s
1 h	0,67 mm	1,11 mm	0,93	12,30 s
2 h	0,82 mm	1,22 mm	0,91	7,92 s
4 h	1,03 mm	1,47 mm	0,87	13,63 s
8 h	1,47 mm	2,11 mm	0,73	23,47 s
16 h	2,08 mm	2,90 mm	0,49	8,29 s
32 h	2,61 mm	3,60 mm	0,21	5,02 s

Les temps d'entraînement doivent être interprétés avec prudence, car ils n'incluent pas l'intégralité du coût de recherche Optuna. Ils correspondent à l'entraînement final avec les hyperparamètres sélectionnés au préalable.

8.2. Dégradation avec l'horizon

Les résultats montrent une dégradation progressive des performances :

- la MAE passe de 0,57 mm à 30 minutes à 2,61 mm à 32 heures,
- la RMSE passe de 1,13 mm à 3,60 mm,
- le R^2 passe de 0,92 à 0,21,

Cette évolution est cohérente avec le fait que l'information contenue dans les 24 dernières heures devient moins prédictive lorsque l'horizon s'éloigne.

À court terme, l'autocorrélation du PWV et les mesures météorologiques locales permettent d'obtenir des prévisions précises. À long terme, le modèle ne dispose pas d'informations sur l'évolution future des masses d'air, ce qui limite mécaniquement ses performances.

8.3. Comparaison des modèles

Modèle	Horizon	MAE	RMSE	R^2
XGBoost	30 min	0,30	0,30	0,99
LSTM	30 min	0,33	0,47	0,99
BiLSTM	30 min	0,39	0,54	0,98
NGBoost optimisé	30 min	0,57	1,13	0,92
XGBoost	4 h	1,07	1,52	0,86
LSTM	4 h	1,09	1,58	0,85
BiLSTM	4 h	1,14	1,65	0,83
NGBoost optimisé	4 h	1,03	1,47	0,87

Ces résultats montrent qu'aucun modèle ne domine nécessairement tous les autres selon tous les critères.

XGBoost offre une excellente précision ponctuelle aux horizons courts. NGBoost apporte une valeur différente : il produit une distribution conditionnelle et permet de calculer des intervalles et des probabilités de dépassement.

Les comparaisons ont été faites tout en portant une attention particulière aux :

- Graines aléatoires fixées
- Nombres d'essais d'optimisation
- Ensembles de validations
- Prétraitements des données

9. Analyse des anomalies

9.1. Définition climatologique

J'ai défini une climatologie du PWV comme la moyenne observée pour chaque couple : *Mois x Heure*. L'anomalie instantanée est définie par la différence entre le PWV observé et la valeur climatologique correspondant au même mois et à la même heure

$$a_t = PWV_t - PWV_{mois(t),he} \quad (t)$$

Cette définition permet de tenir compte des variations saisonnières et journalières du PWV. Une valeur élevée ne constitue donc pas nécessairement une anomalie si elle est habituelle à cette période de l'année et à cette heure de la journée. À l'inverse, un écart important par rapport au comportement moyen peut révéler une situation atmosphérique inhabituelle.

Pour caractériser l'importance des anomalies d'une journée, j'ai utilisé la racine de la moyenne quadratique :

$$A_{jour} = \sqrt{\frac{1}{n} \sum_{t \in jour} a_t^2}$$

Cette mesure permet de prendre en compte à la fois les hausses et les baisses du PWV, sans qu'elles ne se compensent entre elles. Elle fournit ainsi une indication globale de l'écart de la journée par rapport à la climatologie habituelle.

9.2. Résultats sur les anomalies

Le principal échec observé concerne les hausses soudaines et importantes du PWV. Un exemple de hausse soudaine non détecté par le modèle est visible sur la fig.9. Le modèle détecte souvent la variation seulement après son apparition dans les données locales.

Environ une vingtaine d'événements majeurs ont été identifiés dans l'historique étudié. Cet effectif est trop faible pour permettre au modèle d'apprendre de manière robuste les configurations qui précèdent ces événements.

Cette limite est importante : une bonne erreur moyenne ne garantit pas une bonne performance sur les situations les plus critiques pour l'exploitation astronomique.

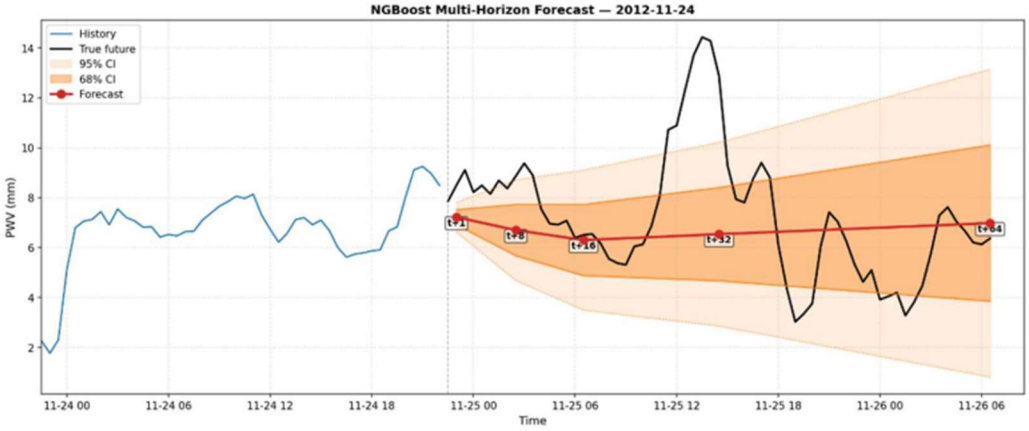


Fig.9 Exemple de prédiction avec anomalie

Source : calculs de l'auteur à partir des données de l'IAC

10. Tableau de bord interactif

10.1. Environnement de développement

J'ai développé le projet sur un serveur distant de l'IAC, accessible via SSH. Tout en mettant en place :

- un environnement virtuel Python
- un fichier requirements.txt
- un dépôt Git
- un dépôt distant GitHub
- une organisation séparant les données, le prétraitement, l'entraînement, l'évaluation et l'interface

L'entraînement du modèle NGBoost est effectué sur CPU. La machine utilisée dispose d'un processeur *Intel Core i9-14900KF*.

10.2. Fonctionnement du dashboard

Afin de rendre les résultats accessibles et de faciliter leur interprétation, j'ai développé une application web interactive à l'aide de Streamlit. Cette application constitue une interface entre les modèles de prévision et l'utilisateur final. Elle permet de consulter les résultats sans avoir à manipuler directement les fichiers de prédiction ou le code Python.

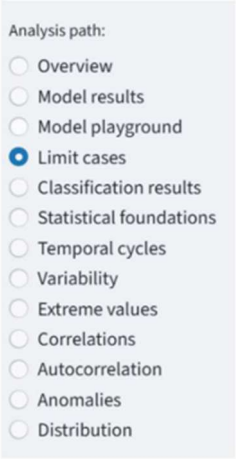


Fig.10 Sommaire du Dashboard *Source : Dashboard de l'auteur*

L’utilisateur peut sélectionner un instant particulier parmi les données de test. À partir de cette sélection, le dashboard présente l’historique récent du PWV ainsi que les prévisions produites par les différents modèles et pour les différents horizons temporels. La représentation graphique permet de comparer la prévision centrale aux valeurs réellement observées après l’instant de prédiction.

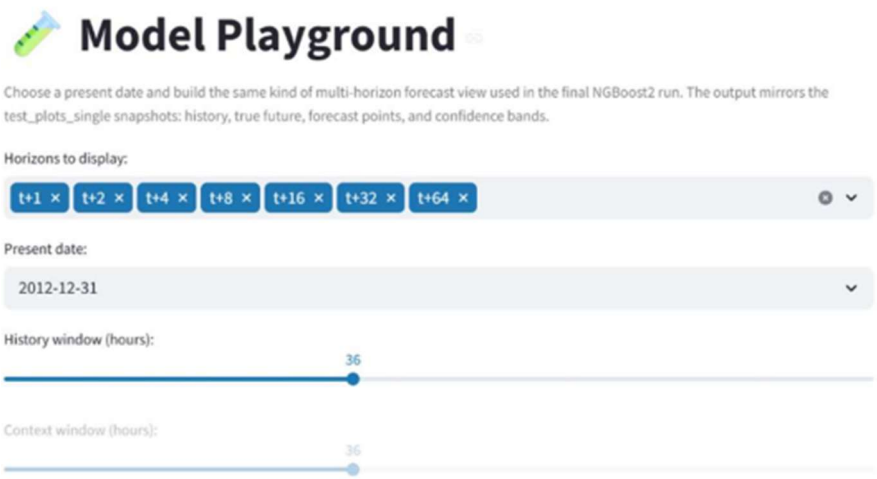


Fig.11 Interface de test du modele

Source : Dashboard de l’auteur

L’interface affiche également les intervalles d’incertitude associés aux prévisions probabilistes. Ces intervalles permettent de visualiser l’étendue des valeurs considérées comme plausibles par le modèle. Plus l’intervalle est large, plus l’incertitude associée à la prévision est importante. Cette information complète la prévision centrale, qui ne suffit pas à elle seule pour évaluer le niveau de confiance du modèle.

Le dashboard permet enfin d’examiner des situations particulières, notamment des exemples de prévisions réussies et des cas d’échec. Cette fonctionnalité est importante pour analyser le comportement du modèle dans des conditions concrètes. Elle permet notamment d’identifier les situations dans lesquelles le modèle suit correctement l’évolution du PWV, mais aussi celles où il reste proche de la dernière observation et reproduit un comportement de persistance.

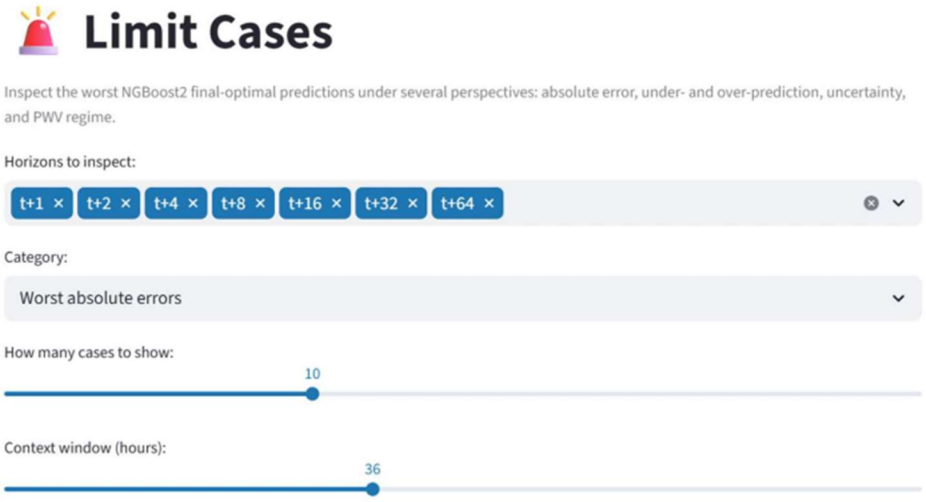


Fig.12 Interface des cas limites

Source : Dashboard de l'auteur

L'outil ne se limite donc pas à présenter une performance moyenne calculée sur l'ensemble du jeu de test. Il permet d'examiner les prédictions à un instant donné, de comparer les différents horizons et de comprendre plus précisément l'origine des erreurs. Il constitue ainsi un support d'analyse scientifique et un moyen de communication avec les équipes de l'IAC.

10.3. Statut de preuve de concept

Le dashboard développé au cours de ce stage constitue actuellement une preuve de concept. Il permet de valider le fonctionnement général de la chaîne de traitement, depuis la sélection d'un instant de référence jusqu'à l'affichage des prévisions et de leur incertitude. Toutefois, il n'est pas encore connecté à un flux de données météorologiques en temps réel et n'est pas utilisé par les opérateurs pour prendre des décisions pendant les observations.

Dans son état actuel, l'application permet de présenter les résultats obtenus aux équipes de l'IAC, de faciliter l'analyse des erreurs et d'illustrer le fonctionnement d'une future interface opérationnelle. Elle offre ainsi un moyen simple d'examiner les prévisions pour des situations particulières et de comparer les performances des modèles selon les horizons temporels.

Le passage à une utilisation opérationnelle nécessiterait plusieurs développements complémentaire. Les données devraient notamment être récupérées

automatiquement, contrôlées avant leur utilisation et transmises au modèle sans intervention manuelle. Une gestion spécifique des valeurs manquantes, des mesures incohérentes et des interruptions de fonctionnement des capteurs serait également nécessaire.

Il serait aussi pertinent de prévoir un mécanisme permettant de signaler l'indisponibilité du modèle ou de fournir une solution alternative. Cette fonctionnalité permettrait de maintenir une information exploitable même lorsque les données nécessaires à l'inférence ne sont pas disponibles.

Une surveillance régulière des performances constituerait également un élément important pour une intégration future. Le suivi des erreurs de prédiction, de la couverture des intervalles d'incertitude et de la fréquence des dépassements de seuil permettrait d'identifier une éventuelle dégradation des performances au cours du temps.

Enfin, l'interface définitive devra être adaptée aux pratiques des opérateurs de l'observatoire et aux logiciels déjà utilisés par l'IAC. Le dashboard Streamlit développé pendant le stage constitue donc une base de démonstration et d'évaluation, mais ne prétend pas remplacer une solution opérationnelle complète.

11. Étude exploratoire d'un modèle fondation de séries temporelles

En complément des modèles développés localement, j'ai étudié le modèle probabiliste **T0 de The Forecasting Company**.

L'objectif était d'évaluer si un modèle préentraîné sur de nombreuses séries temporelles pouvait être adapté au PWV avec peu d'apprentissage supplémentaire. J'ai utilisé un contexte de 48 observations, correspondant à 24 heures de mesures.

J'ai également expérimenté une adaptation par LoRA. Cette méthode consiste à entraîner un petit nombre de paramètres supplémentaires tout en conservant la majorité des poids du modèle d'origine.

Les premiers essais n'ont pas montré d'amélioration significative après le fine-tuning. Ce résultat doit toutefois être considéré comme exploratoire, car :

- Les évaluations ont été réalisées sur des portions réduites du dataset
- La longueur du contexte et les modules adaptés pourraient ne pas être optimaux
- La comparaison avec NGBoost n'a pas encore été conduite sur un protocole strictement identique

Cette expérience m'a néanmoins permis d'explorer une approche récente de transfert d'apprentissage appliquée aux séries temporelles.

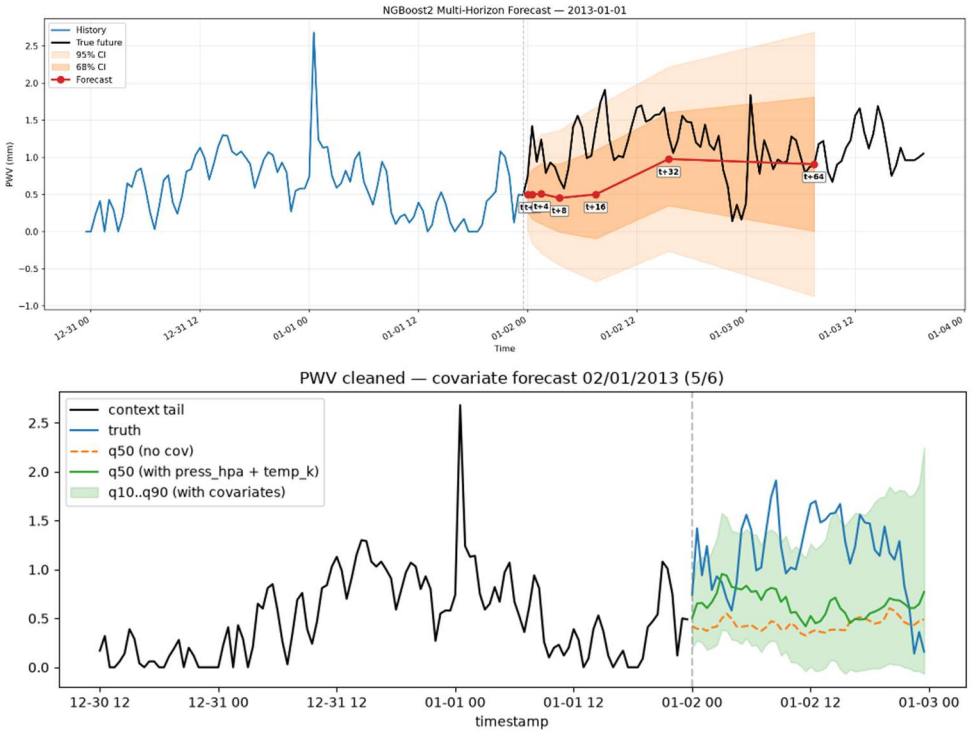


Fig.13 Comparaison entre une prédiction NGBoost et TFC-T0(LoRA)

Source : calculs de l'auteur à partir des données de l'IAC

12. Préparation d'une publication scientifique

12.1. Objectif de valorisation

Compte tenu de la dimension scientifique du projet, j'ai engagé la préparation d'une publication en anglais consacrée à la prévision probabiliste multi-horizons du PWV.

Les coauteurs potentiels identifiés sont :

- Felix Vernin, ESIEE Paris et IAC,
- Andrés Asensio Ramos, IAC,
- Casiana Muñoz-Tuñón, IAC,
- Julio Castro Almazan, IAC.

L'ordre définitif des auteurs et leurs contributions devront être validés collectivement selon les pratiques scientifiques de l'IAC et de la revue ciblée.

À ce stade, aucune revue n'a été définitivement sélectionnée.

12.2. Ma contribution à la publication

Dans le cadre de cette préparation, j'ai :

- Formalisé la problématique scientifique,
- Décrit le protocole de séparation chronologique,
- Vérifié les principales sources possibles de fuite de données,
- Recensé les variables et les étapes de feature engineering,
- Documenté l'implémentation de NGBoost,
- Extrait les hyperparamètres finaux par horizon,
- Rassemblé les métriques disponibles,
- Identifié les informations manquantes nécessaires à une soumission,
- Préparé une première structure d'article en anglais,
- Analysé les limites méthodologiques du travail,
- Recensé les conditions de reproductibilité,

Ce travail de formalisation m'a conduit à approfondir certains aspects qui étaient moins explicites dans le développement initial, notamment la calibration, la définition reproductible des anomalies et l'équité des comparaisons entre modèles.

12.3. Conditions nécessaires avant soumission

Avant une éventuelle soumission, plusieurs éléments devront être consolidés

- Documenter toutes les variables,
- Recalculer les métriques sur un échantillon commun,
- Présenter les couvertures avant et après calibration,
- Évaluer le modèle sur les dépassements de seuil,
- Préciser la contribution de chaque coauteur,
- Choisir une revue adaptée,

La publication est pour le moment en cours d'élaboration, mais n'est pas encore soumise ou acceptée.

13. Contribution personnelle

Ma contribution ne s'est pas limitée à l'entraînement d'un modèle existant. J'ai pris en charge une chaîne de travail couvrant l'ensemble du cycle d'un projet de machine learning appliqué :

- Compréhension du besoin astronomique,
- Exploration des sources de données,
- Diagnostic des limites du pipeline satellitaire,
- Réorientation vers les mesures locales,
- Nettoyage et analyse statistique,
- Création de variables temporelles,
- Conception du protocole expérimental,
- Implémentation et comparaison de plusieurs modèles,
- Optimisation avec Optuna,
- Développement de stratégies anti-persistance,
- Calibration des intervalles probabilistes,
- Analyse des événements extrêmes,
- Développement du dashboard,
- Gestion du code avec Git,
- Documentation scientifique,
- Préparation d'une publication en anglais,

Les décisions scientifiques ont été discutées avec mes encadrants, mais j'ai personnellement réalisé l'implémentation, les expérimentations, la production des résultats et la conception du démonstrateur.

14. Limites du travail

Plusieurs limites doivent être prises en compte.

Ancienneté et volume des données

Le dataset couvre uniquement 2012 et 2013. Il ne permet pas d'évaluer directement la capacité du modèle à fonctionner sur les conditions atmosphériques actuelles.

Faible nombre d'événements extrêmes

Les hausses brutales du PWV sont peu nombreuses. Le modèle apprend donc principalement les régimes stables et les variations fréquentes.

Absence de variables météorologiques futures

Le modèle utilise les observations disponibles jusqu'à l'instant de prévision, mais pas de prévisions météorologiques telles que WRF. Cette absence limite particulièrement les horizons longs.

Distribution normale

NGBoost utilise actuellement une loi normale, qui autorise théoriquement des valeurs négatives de PWV. Aucune contrainte explicite n'a encore été mise en place.

Une distribution positive, une transformation logarithmique ou une troncature physique pourraient être étudiées.

Comparaison imparfaite des modèles

Les budgets d'optimisation et les conditions exactes doivent être davantage harmonisés pour garantir une comparaison totalement équitable.

Seuil opérationnel simplifié

Le seuil de 5 mm ne résume pas à lui seul les contraintes de tous les instruments infrarouges. Une analyse par bande spectrale ou par instrument renforcerait l'utilité opérationnelle du système.

15. Perspectives

Les résultats obtenus au cours de ce stage montrent l'intérêt de modèles probabilistes pour prévoir le PWV à plusieurs horizons temporels. Toutefois, plusieurs prolongements permettraient d'améliorer la robustesse des résultats et de rapprocher progressivement la méthode d'un usage opérationnel.

15.1. Réentraînement sur des données récentes

Une première perspective consiste à compléter le jeu de données par un historique plus récent et plus long. Les données utilisées dans cette étude couvrent une période limitée, ce qui réduit le nombre d'événements atmosphériques rares disponibles pour l'entraînement et l'évaluation.

L'ajout de nouvelles observations permettrait d'augmenter le nombre de situations extrêmes et d'améliorer l'apprentissage des épisodes caractérisés par des variations rapides du PWV.

Ces données supplémentaires permettraient aussi d'étudier plus précisément les effets saisonniers. Les comportements atmosphériques pouvant différer selon la période de l'année, l'analyse pourrait être menée séparément pour chaque saison ou pour différents régimes météorologiques. Enfin, l'utilisation de données récentes constituerait une étape importante pour évaluer la pertinence des modèles dans un contexte météorologique et instrumental plus proche des conditions opérationnelles actuelles.

15.2. Intégration de prévisions météorologiques

Une autre évolution possible serait d'intégrer au modèle des prévisions météorologiques produites par le système WRF. Contrairement aux seules mesures locales, ces prévisions pourraient fournir des informations sur l'évolution des masses d'air avant leur arrivée sur le site d'observation. Elles pourraient ainsi aider à anticiper certaines variations du PWV qui ne sont pas encore visibles dans l'historique local.

L'intérêt de cette intégration pourrait être étudié à travers plusieurs configurations expérimentales. Une première configuration utiliserait uniquement la persistance, afin de disposer d'une référence simple. Une deuxième s'appuierait exclusivement sur les mesures locales, comme dans l'approche présentée dans ce rapport. Une troisième utiliserait uniquement les variables issues de WRF. Enfin, une dernière configuration combinerait les observations locales et les prévisions météorologiques.

Cette comparaison permettrait d'identifier la contribution réelle de chaque source d'information. Elle pourrait également montrer si les données météorologiques apportent un gain principalement pour les horizons longs, tandis que les mesures locales seraient davantage utiles pour les prévisions à court terme.

15.3. Déploiement en temps réel

Le dashboard développé pendant le stage constitue une preuve de concept et permet de visualiser les prévisions produites par les modèles. Une utilisation en temps réel nécessiterait toutefois une chaîne de traitement automatisée, capable de récupérer régulièrement les nouvelles mesures et de générer une prévision toutes les trente minutes.

Cette chaîne devrait intégrer des contrôles permettant d'identifier les données manquantes, incohérentes ou temporairement indisponibles. Les prédictions produites devraient également être sauvegardées afin de conserver un historique des résultats et de permettre un suivi continu des performances.

À plus long terme, la surveillance de la dérive des données et des performances permettrait de détecter une modification des conditions de fonctionnement du système. Un mécanisme de réentraînement pourrait alors être envisagé lorsque les nouvelles observations deviennent suffisamment nombreuses ou lorsque les performances diminuent.

Enfin, une intégration avec les outils utilisés par les opérateurs faciliterait l'exploitation des prévisions dans le processus de planification des observations. Ces développements dépassent le cadre du stage, mais constituent les principales étapes identifiées pour transformer le prototype actuel en un outil utilisable dans un environnement opérationnel.

16. Bilan des compétences développées

16.1. Formaliser les besoins et les attentes liés à un projet

Le projet répondait à un besoin concret : améliorer la prévision du contenu intégré en vapeur d'eau précipitable afin de faciliter l'anticipation des conditions atmosphériques défavorables aux observations astronomiques. J'ai dû traduire cette demande en objectifs techniques et scientifiques mesurables.

Cette formalisation m'a conduit à définir les horizons de prévision, les variables utilisées, les différentes références de comparaison ainsi que les métriques adaptées à l'évaluation des modèles. J'ai également pris en compte les attentes des encadrants concernant la fiabilité des prévisions, l'estimation de l'incertitude et la possibilité d'interpréter les résultats dans une interface visuelle.

16.2. Concevoir une solution d'ingénierie complexe

La conception de la solution s'est appuyée sur une démarche progressive. J'ai d'abord établi une baseline de persistance, puis étudié plusieurs familles de modèles capables de produire des prévisions probabilistes. Cette approche m'a permis de comparer différentes solutions en tenant compte des contraintes du projet, notamment la quantité de données disponible, la structure temporelle du problème et la nécessité d'obtenir des intervalles d'incertitude calibrés.

J'ai également conçu un protocole expérimental fondé sur une séparation chronologique des données. Ce choix permet d'éviter les fuites d'information entre l'entraînement et l'évaluation et de reproduire plus fidèlement les conditions d'une utilisation future. La conception du dashboard Streamlit constitue enfin une preuve de concept permettant de transformer les sorties des modèles en informations directement visualisables.

16.3. Réaliser une solution d'ingénierie complexe

J'ai réalisé l'ensemble de la chaîne de traitement nécessaire à l'étude : préparation des données, création des variables explicatives, entraînement des modèles, réglage des hyperparamètres, génération des prévisions et évaluation des performances.

Ce travail m'a permis de créer et d'adapter différents composants logiciels à l'aide de Python, notamment avec les bibliothèques pandas, NumPy, scikit-learn, XGBoost, NGBoost et Optuna. J'ai également développé une interface avec Streamlit afin de rendre les résultats accessibles et d'examiner le comportement des modèles sur des situations particulières.

La validation a reposé sur plusieurs critères, tels que l'erreur de prévision, le CRPS, la couverture des intervalles et leur largeur moyenne. Cette évaluation m'a permis de

comparer les modèles, d'identifier leurs limites et de vérifier que leurs incertitudes restaient cohérentes avec les observations.

16.4. Gérer un projet

La réalisation du stage m'a conduit à organiser les différentes étapes du projet en fonction des objectifs, des contraintes techniques et du temps disponible. Une difficulté importante est apparue lors de l'extraction des données satellitaires, dont la fiabilité et la stabilité ne permettaient pas une intégration satisfaisante dans le délai du stage.

J'ai alors réorienté la stratégie vers une approche fondée principalement sur les mesures locales. Cette décision reposait sur un compromis entre l'ambition initiale, la robustesse des données disponibles et la nécessité d'obtenir des résultats vérifiables. Cette expérience m'a appris à identifier les risques, à adapter les priorités et à rendre compte des choix effectués.

La structuration du code, la conservation des résultats d'expériences et l'utilisation de Git et GitHub ont également contribué à améliorer la traçabilité et la reproductibilité du travail.

16.5. Agir avec une démarche scientifique et éthique

Cette compétence a été particulièrement mobilisée au cours du stage. J'ai transformé une problématique opérationnelle en hypothèses testables et en un protocole expérimental explicite. La validation chronologique, la comparaison avec une baseline et l'utilisation de plusieurs métriques m'ont permis d'évaluer les modèles de manière rigoureuse.

J'ai également analysé les résultats négatifs et les limites de l'étude, notamment les performances insuffisantes de certains modèles, la production éventuelle de valeurs négatives et la difficulté à prévoir les événements brusques. Ces limites ont été présentées comme des éléments de l'analyse et non comme des résultats à dissimuler.

Enfin, j'ai veillé à distinguer les résultats directement mesurés des interprétations qui en découlent. Cette démarche m'a permis de justifier mes choix méthodologiques et de conserver une analyse aussi objective que possible.

16.6. Communiquer avec pertinence et efficacité

La rédaction du rapport final m'a permis de développer ma capacité à présenter une démarche scientifique de manière structurée. J'ai dû expliquer le contexte du projet, décrire les méthodes employées, présenter les résultats chiffrés et mettre en évidence les limites de l'approche.

Les échanges réguliers avec mes encadrants m'ont également appris à adapter le niveau de détail et à justifier mes choix techniques. La préparation d'un article en

anglais m'a permis de renforcer ma capacité à communiquer des résultats scientifiques dans un contexte international.

Le dashboard constitue un autre support de communication. Il permet de présenter les avancements sous une forme plus accessible qu'un ensemble de tableaux ou de métriques.

16.7. Intervenir dans un contexte international et multiculturel

Le stage réalisé à l'IAC m'a placé dans un environnement international, avec des échanges professionnels en anglais et une collaboration avec des interlocuteurs issus de cultures et de domaines différents.

La rédaction et la préparation d'un article en anglais m'ont conduit à adapter mon vocabulaire et ma manière de présenter les résultats. J'ai également dû prendre en compte les pratiques de communication propres à un contexte de recherche international. Cette expérience m'a permis de gagner en autonomie dans les échanges professionnels et de mieux comprendre l'importance de l'adaptation aux interlocuteurs et aux cultures métier.

16.8. Être innovant et créatif

Le caractère exploratoire du projet m'a amené à tester plusieurs approches de modélisation et à comparer leurs avantages et leurs limites. L'utilisation de modèles probabilistes pour prévoir le PWV ne consistait pas uniquement à produire une valeur centrale : elle visait également à quantifier l'incertitude et la probabilité de dépasser un seuil opérationnel.

La création du dashboard Streamlit s'inscrit dans cette démarche d'innovation. Elle permet de relier les résultats de la modélisation à un usage concret en offrant une représentation visuelle des prévisions et de leurs incertitudes.

17. Conclusion

Ce stage avait pour objectif d'évaluer la faisabilité d'une prévision probabiliste multi-horizons de la vapeur d'eau précipitable à partir de mesures locales effectuées à Izaña.

J'ai construit un pipeline complet couvrant la préparation des données, l'ingénierie des variables, l'entraînement, l'optimisation, l'évaluation et la visualisation. J'ai comparé plusieurs architectures et approfondi NGBoost afin de produire une distribution prédictive pour chaque horizon.

Les résultats montrent qu'une approche de machine learning permet de prévoir efficacement le PWV aux horizons courts et intermédiaires. Pour NGBoost, la MAE évolue de 0,57 mm à 30 minutes à 2,61 mm à 32 heures. Cette dégradation traduit la diminution de l'information prédictive disponible lorsque l'horizon s'éloigne.

La contribution principale de l'approche probabiliste réside dans la possibilité de fournir une valeur prévue, un intervalle d'incertitude et une probabilité de dépassement du seuil de 5 mm. La calibration de cette incertitude est indispensable pour transformer une sortie mathématique en information utile à la décision.

La principale limite concerne les événements rares et brusques. Leur faible nombre dans le dataset et l'absence de prévisions météorologiques externes empêchent le modèle de les anticiper de manière fiable.

Le dashboard développé permet de présenter les résultats de façon transparente et d'examiner aussi bien les succès que les échecs du modèle. Ce travail constitue une preuve de concept, mais il devra être prolongé par l'utilisation de données récentes, une validation plus approfondie et l'intégration de sources météorologiques externes avant un déploiement opérationnel.

Enfin, la préparation d'une publication scientifique offre une perspective de valorisation du travail et contribue à formaliser les conditions nécessaires à sa reproductibilité.

18. Bibliographie

[1] T. Duan, A. Avati, D. Y. Ding, K. K. Thai, S. Basu, A. Y. Ng, and A. Schuler, "NGBoost: Natural Gradient Boosting for Probabilistic Prediction," in Proc. 37th Int. Conf. Mach. Learn. (ICML), vol. 119. PMLR, 2020, pp. 3545–3556.

[2] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Mining, 2016, pp. 785–794.

[3] S. Hochreiter and J. Schmidhuber, "Long Short-Term Memory," Neural Comput., vol. 9, no. 8, pp. 1735–1780, 1997.

[4] B. García-Lorenzo, J. A. Castro-Almazán, and C. Muñoz-Tuñón, "Astronomical site testing in the Canary Islands," in Proc. SPIE, 2010, vol. 7734, p. 773448.

[5] M. O'Neill, C. Tucker, and M. Kumar, "Machine Learning for Atmospheric Parameter Forecasting in Astronomy," Publ. Astron. Soc. Pac., vol. 133, 2021.

[6] J. A. Castro-Almazán, C. Muñoz-Tuñón, B. García-Lorenzo, G. Pérez-Jordán, A. M. Varela, and I. Romero, "Precipitable Water Vapour at the Canarian Observatories from Routine GPS," in Proc. SPIE, Observatory Operations: Strategies, Processes, and Systems VI, 2016, vol. 9910.

[7] G. Pérez-Jordán, J. A. Castro-Almazán, and C. Muñoz-Tuñón, "Precipitable Water Vapour Forecasting: A Tool for Optimizing IR Observations at Roque de los Muchachos Observatory," Mon. Not. R. Astron. Soc., vol. 477, no. 4, pp. 5477–5485, 2018.